Rapport Final – Prédiction du Churn Client

Projet : Analyse Big Data & IA pour l'anticipation et la réduction du Churn Client chez TelcoX

1.Contexte et Objectifs

1.1 Enjeu de l'Attrition (Churn)

Le taux de résiliation des clients TelcoX est en hausse depuis plusieurs trimestres, impactant directement la rentabilité de l'entreprise — l'acquisition d'un nouveau client étant jusqu'à **5 fois plus coûteuse que la fidélisation**.
L'objectif stratégique est donc d'**identifier les clients à haut risque de départ** pour mener des actions préventives et ciblées.

1.2 Type de Tâche

- **Classification supervisée binaire**
  - Churn = 1 → client résilie
  - Churn = 0 → client reste
- **Déséquilibre de classes** : environ **20 %** de churners.

1.3 Objectifs Métier et Métriques

Objectif	Description
Maximiser le Recall (Churn)	Détecter un maximum de clients à risque, même au prix de quelques faux positifs.
Maintenir une Précision élevée	Éviter les campagnes inutiles auprès de clients fidèles.
Optimiser l'AUC-ROC	Assurer une forte capacité de discrimination globale du modèle.

2.Préparation et Construction des Données

2.1 Sources de Données

- **clients.csv** → Informations démographiques et profil.
- **contracts.csv** → Type, durée et conditions du contrat.
- **usage.csv** → Données de consommation (appels, data, facturation).
- **interactions.csv** → Feedback client, satisfaction et interactions.

2.2 Intégration et Nettoyage

- Jointures successives via la clé customerID.
- Nettoyage : suppression des doublons, harmonisation (strip(), renommage).
- Conversion de types (TotalCharges, MonthlyCharges etc.).
- Suppression des clients avec tenure < 1 mois.
- Imputation : médiane (numérique) et mode (catégorielle).

3.Analyse Exploratoire (EDA)

3.1 Distribution de la Variable Cible

- **~21 % de churners** → fort déséquilibre à corriger (SMOTE, class_weight).

3.2 Corrélations et Observations

Variable	Observation	Interprétation
ContractTypes	Le churn est plus fort pour les contrats *Month-to-month*.	Manque d'engagement → volatilité.
InternetService	Les clients *Fiber optic* churnent davantage.	Attentes élevées en performance → insatisfaction potentielle.
MonthlyCharges	Plus les charges mensuelles sont élevées, plus le risque augmente.	Sensibilité au prix.
SatisfactionScore	Score faible = fort taux de churn.	Indicateur clé de satisfaction.

3.3 Visualisations Clés (dans Streamlit)

- Histogrammes et boxplots.
- Heatmap de corrélation.
- Matrice de confusion dynamique.
- WordClouds du FeedbackText (anglais).

4.Prétraitement et Pipeline Modulaire

4.1 Structure du Pipeline

Type de variable	Transformation
Numérique	Imputation médiane + StandardScaler
Catégorielle	Imputation mode + OneHotEncoder
Texte (FeedbackText)	TF-IDF (max_features=200, stop_words='english')

4.2 Gestion du Déséquilibre

Deux approches combinées :

1. **SMOTE** (Sur-échantillonnage de la classe minoritaire).
2. **Class Weights** (balanced_subsample).

Résultat : amélioration du **recall sans perte de précision**.

5.Modélisation et Optimisation

5.1 Modèles Testés

Modèle	Description	Recall	F1	AUC	Observation
Logistic Regression	Baseline linéaire	0.62	0.71	0.84	Simple, mais sous-performe.
Random Forest	Ensemble d'arbres	0.78	0.87	0.98	Excellent compromis.
Random Forest + SMOTE	Modèle final	0.76–0.79	0.87	0.978	Meilleur équilibre global.

5.2 Optimisation des Hyperparamètres

```
best_rf_params = {
    "n_estimators": 800,
    "max_depth": 15,
    "min_samples_split": 2,
    "min_samples_leaf": 1,
    "max_features": "log2",
    "random_state": 42,
    "class_weight": "balanced_subsample"
}
```

Compromis optimal entre performance et stabilité, sans surapprentissage.

6.Ajustement du Seuil de Décision

Seuil	Recall	Precision	F1	Interprétation
0.50	0.76	1.00	0.87	Très haute précision, recall moyen.
0.35–0.40	0.85–0.90	0.97	0.89	Rappel accru avec légère baisse de précision.

Implémenté dans Streamlit : slider interactif pour ajuster le seuil et visualiser en direct les impacts sur les métriques.

7.Évaluation du Modèle Final

Métrique	Classe 0 (Non-Churn)	Classe 1 (Churn)	Macro Avg	Weighted Avg
Precision	0.94	1.00	0.97	0.95
Recall (Rappel)	1.00	0.76	0.88	0.95
F1-Score	0.97	0.87	0.92	0.95
Support	874	240	1114	1114
Accuracy	-	-	**0.95**	-

Conclusion :

- Excellente généralisation, pas d'overfitting.
- Modèle robuste, Recall équilibré et Précision parfaite.

8.Interprétation des Facteurs Clés (Feature Importance)

Rang	Feature	Interprétation Métier	Risque
1	tenure	Ancienneté faible = risque élevé.	**élevé**
2	ContractType_Month-to-month	Contrats sans engagement → forte volatilité.	**élevé**
3	MonthlyCharges	Plus la facture est élevée, plus le risque augmente.	**modéré**
4	AvgChargePerMonth	Ratio coût / ancienneté.	**modéré**
5	SatisfactionScore_No Response	Silence client = alerte potentielle.	**modéré**
6	TF-IDF terms (slow, disconnect, expensive)	Feedback négatifs → qualité de service en cause.	**élevé**
7	InternetService_Fiber optic	Attentes élevées → risque de churn si problème.	**modéré**

9.Analyse Textuelle (FeedbackText)

- **Langue** : Anglais
- **Méthode** : TF-IDF Vectorizer (stop_words='english', max_features=200)
- **Résultats :**
  - Les churners utilisent plus de mots liés à **“slow”, “disconnect”, “expensive”, “cancel”**.
  - Les non-churners utilisent **“good”, “satisfied”, “happy”, “service”**.
- **Interprétation** :
  - Le **feedback client textuel est un indicateur comportemental fort**.
  - Permet de déclencher des alertes automatiques côté support.

Recommandations Métier

10.1 Ciblage et Actions Prioritaires

Risque	Observation	Action Recommandée	Équipe
1 Nouveaux Clients / Contrats flexibles	Forte volatilité	Offres de conversion vers contrats 12–24 mois (remises ciblées).	Marketing
2 Silence ou Feedback Négatif	Problèmes non résolus	Alerte Support automatique + relance proactive.	Support
3 Charges Mensuelles Élevées	Sensibilité prix	Offres personnalisées de fidélisation.	Commercial

10.2 Ajustement du Seuil de Décision

- **Seuil actuel (0.5)** : précision parfaite, recall moyen.
- **Seuil optimal (0.35–0.40)** : meilleure couverture du risque avec recall accru.

10.3 Prochaines Étapes Techniques

1. **Déploiement Streamlit** en production (scoring en temps réel).
2. **Interprétabilité locale** via SHAP ou LIME.
3. **MLOps** : réentraînement périodique automatique.
4. **Amélioration NLP** : intégration de modèles BERT embeddings pour mieux capter les nuances du langage client.

Résumé Final

Critère	Résultat
Meilleur Modèle	Random Forest + SMOTE + TF-IDF
Recall (Churn)	0.76 – 0.79
Precision (Churn)	~1.00
F1-score	~0.87
AUC-ROC	~0.978
Outil Déployé	Application Streamlit interactive
Impact Métier	Identification proactive des churners avec haute fiabilité

Recommandations Opérationnelles Détaillées

A. Stratégie de Modélisation et de Seuil (Tactique)

Recommandation I.A : Ajuster le Seuil pour le Rappel

- **Action :** Fixez un nouveau seuil de décision (par exemple, autour de **0.15 à 0.25**) dans votre dashboard Streamlit pour augmenter le **Rappel** à un niveau jugé acceptable (par exemple, **> 85%**).
- **Justification Métier :** En rétention, il est généralement plus rentable d'accepter quelques Faux Positifs (cibler des non-churners, coût marketing) que d'avoir de nombreux Faux Négatifs (perdre de vrais churners, coût de la perte du revenu client).

Recommandation I.B : Suivi et Ré-entraînement

- **Action :** Mettre le modèle en production (via API) et établir un processus de **ré-entraînement mensuel** pour capter l'évolution des comportements (notamment les poids du FeedbackText).

B. Programme d'Engagement (Rétention Proactive)

Recommandation II.A : Programme (Tenure)

- **Action :** Mettre en place un programme intensif et personnalisé pour les clients dans le segment **[0, 6] mois** (basé sur le diagnostic de forte concentration du Churn).
- **Exemples :** Appels de suivi proactifs du support client, tutoriels personnalisés sur les fonctionnalités premium, offre d'un mois de service gratuit à l'approche du 6e mois.

Recommandation II.B : Conversion Contractuelle

- **Action :** Ciblez agressivement les clients en contrat Month-to-month (particulièrement ceux avec un SatisfactionScore moyen ou faible) avec des **incitations financières claires** pour la conversion vers 1 an ou 2 ans.
- **Objectif :** Utiliser les contrats longs comme des **facteurs protecteurs** pour réduire le risque de Churn à court terme.

C. Amélioration du Service (Qualité Produit et Support)

Recommandation III.A : Urgence Fiber Optic

- **Action :** Les équipes techniques et produit doivent prioriser l'amélioration de la stabilité et de la qualité de service pour les abonnés **Fiber Optic**.
- **Justification :** Le risque élevé suggère que les clients paient pour une performance élevée qu'ils n'obtiennent pas de manière fiable.

Recommandation III.B : Alerte de Frustration (Support)

- **Action :** Déployer une règle métier immédiate : tout client atteignant **3 contacts au support en 30 jours** (ou un score de **Satisfaction 1 ou 2**) doit être transféré en temps réel à un **manager de rétention senior** pour une résolution immédiate et personnalisée.
- **Objectif :** Intervenir avant que la frustration ne devienne une décision de résiliation.

D. Optimisation des Prix (Pricing/Marketing)

Recommandation IV.A : Audit de la Valeur pour les Hauts Payeurs

- **Action :** Réaliser un audit des services associés aux forfaits les plus chers. Pour les clients à hauts MonthlyCharges identifiés comme à risque, **ajouter gratuitement des fonctionnalités premium** pour rétablir la perception de la valeur.
- **Justification :** Le risque élevé lié au prix suggère qu'ils sont en phase de comparaison avec la concurrence.